

Agent Atlas

Agent 工程技术专著：从范式源流到生产系统

Agent Atlas Contributors

目录

1	Agent Atlas	7
	写在前面	9
2	阅读指南与工程约定	11
	阅读指南与工程约定	13
2.1	如何读这本书	13
2.2	证据等级	13
2.3	实验约定	13

I

第一篇：范式与基础

3	从符号主义、BDI、规划和强化学习到 LLM Agent	17
4	从符号主义、BDI、规划和强化学习到 LLM Agent	19
4.1	本章要解决的问题	19
4.2	作为起点的“理性智能体”	20
4.3	符号规划：把世界写成可搜索的状态空间	20
4.4	BDI：在动态环境中管理承诺	21
4.5	反应式与分层控制：不是所有行动都需要“想很久”	22
4.6	强化学习：从给定计划转向从交互中学习策略	22
4.7	基础模型：状态不再完全依赖人工建模	22
4.8	ReAct 与工具使用：语言推理进入环境闭环	23
4.9	控制权如何在系统中重新分配	23
4.10	贯穿案例：变更决策系统的五次演化	25
4.10.1	第一版：规则与模板	25
4.10.2	第二版：符号约束	25
4.10.3	第三版：BDI 式运行状态	25
4.10.4	第四版：检索增强的 LLM Agent	25

4.10.5	第五版：评测驱动的混合系统	25
4.11	架构选择：从最小不确定性开始	25
4.12	常见误区与失败模式	26
4.12.1	误区一：把会调用函数等同于 Agent	26
4.12.2	误区二：把自然语言计划当成真实状态	26
4.12.3	误区三：把长期记忆当成持续学习	26
4.12.4	误区四：用多 Agent 掩盖单体设计问题	26
4.12.5	误区五：用提示词承担强约束	26
4.13	生产决策清单	26
4.14	本章小结	27
4.15	思考与实践	27

II

第二篇：从零理解核心机制

5	工具契约、结构化交互与安全执行环境	31
6	工具契约、结构化交互与安全执行环境	33
6.1	本章要解决的问题	33
6.2	工具不是函数：它是模型与环境之间的 ACI	34
6.3	五份契约	35
6.3.1	语义契约：降低选择歧义	35
6.3.2	数据契约：先验证，再产生效果	35
6.3.3	策略契约：模型不拥有授权权	36
6.3.4	执行契约：把副作用当作分布式事务	36
6.3.5	观测契约：记录决策结果，不记录隐藏推理	37
6.4	一次工具调用的完整生命周期	37
6.5	错误语义与恢复	38
6.6	工具结果是不可信输入	39
6.7	代码执行：能力越通用，隔离越具体	39
6.8	动态发现与 MCP 的边界	39
6.9	贯穿案例：安全的变更方案生成	40
6.10	框架抽象与可移植性	40
6.11	失败图谱	41
6.11.1	工具描述漂移	41
6.11.2	审批后参数被替换	41
6.11.3	超时后的双重效果	41

6.11.4 错误信息诱导递归 41

6.11.5 结果污染长期记忆 41

6.11.6 工具集合过大 41

6.12 生产检查清单 41

6.13 本章小结 42

6.14 思考与实践 42

参考资料 43

参考文献 45

1. Agent Atlas

Agent 工程技术专著：从范式源流到生产系统

写在前面

Agent 技术真正困难的部分，不是学会调用某个 SDK，而是把概率模型嵌入一个可验证、可恢复、可授权、可运营的软件系统。对资深后端工程师而言，新的挑战不在于忘掉过去，而在于重新理解控制流：一部分控制权从确定性程序移交给模型以后，系统必须用工具契约、状态机、评测、权限和反馈重新建立边界。

本书沿三条线索展开：Agent 从哪里来，2026 年的工程系统处在什么阶段，以及未来哪些变化值得提前准备。它不会把产品功能表当作知识体系，也不会把“自主”当作默认目标。每一种模式都必须回答：为什么需要它、引入了什么新能力、产生了什么新故障，以及如何证明它比更简单的方案更好。

当前版本是 v2 foundation 审核包，只包含两篇完整样章。它的目的不是营造“全书已经完成”的错觉，而是让读者和维护者先审核叙事深度、代码抽象、图表语言、引用方式和 PDF 阅读体验。审核通过后，余下章节才按相同标准展开。

适合读者：有多年后端、分布式系统、平台工程或技术管理经验，希望转型 Agent 工程、AI 平台或智能应用架构方向的工程师。

不要求：训练过基础模型或掌握复杂的深度学习推导。

要求：能阅读 Python/TypeScript，理解 API、状态、并发、权限、测试和生产运维。

2. 阅读指南与工程约定

阅读指南与工程约定

2.1 如何读这本书

如果你的目标是系统转型，建议按章节顺序阅读，并亲自运行实验。若你负责技术决策，可以先读第一篇建立术语，再跳到第三、四篇；若你正在建设平台，则应优先关注运行状态、工具边界、持久执行、评测和安全，而不是多 Agent 的角色命名。

每章都从一个工程问题开始，随后解释范式来源、机制、架构选择、代码、故障模式和生产约束。正文中的“稳定”表示概念或实践已有长期证据；“演进中”表示接口、协议或行业共识仍可能变化；“实验性”和“推测性”内容必须给出验证信号。

2.2 证据等级

1. 一手证据：论文、正式规范、官方文档、官方仓库与发布记录。
2. 权威实践：标准组织、安全机构和公开的生产工程复盘。
3. 交叉验证：多个相互独立实现对同一工程规律的支持。
4. 推断与情景：基于事实形成的判断，必须标注置信度和可证伪信号。

产品文档只能证明“某产品在某个时间提供了某能力”，不能单独证明该设计对所有系统都有效。排行榜只能证明特定任务、数据、环境和成本条件下的结果，不能代替生产选型。

2.3 实验约定

默认实验使用确定性的 Fake Model 和本地夹具，不读取密钥、不访问网络。模型返回的是可审计决策对象，而不是隐藏推理过程。真实模型适配器必须实现同一份公共契约，并在显式开启时运行。

实验事件只记录输入摘要、模型决策、工具参数、策略判定、工具结果、状态变化、预算和最终状态。这些信息足以复现系统行为，也避免把不可依赖的私有推理当作接口。



第一篇： 范式与基础

3	从符号主义、BDI、规划和强化学习到 LLM Agent	17
4	从符号主义、BDI、规划和强化学习到 LLM Agent	19
4.1	本章要解决的问题	19
4.2	作为起点的“理性智能体”	20
4.3	符号规划：把世界写成可搜索的状态空间 . . .	20
4.4	BDI：在动态环境中管理承诺	21
4.5	反应式与分层控制：不是所有行动都需要“想很久”	22
4.6	强化学习：从给定计划转向从交互中学习策略	22
4.7	基础模型：状态不再完全依赖人工建模	22
4.8	ReAct 与工具使用：语言推理进入环境闭环 . .	23
4.9	控制权如何在系统中重新分配	23
4.10	贯穿案例：变更决策系统的五次演化	25
4.11	架构选择：从最小不确定性开始	25
4.12	常见误区与失败模式	26
4.13	生产决策清单	26
4.14	本章小结	27
4.15	思考与实践	27

3. 从符号主义、BDI、规划和强化学习到 LLM Agent

4. 从符号主义、BDI、规划和强化学习到 LLM Agent

今天的 LLM Agent 并没有取消经典智能体问题。它只是把“如何表示世界、如何选择行动、如何从反馈中修正”中的一部分，从显式程序转移到预训练模型。理解这段演化的价值，不是背年代，而是知道每种范式把复杂性放在了哪里。

4.1 本章要解决的问题

软件行业很容易把 Agent 的历史压缩成一条营销叙事：过去是规则，现在是大模型，未来是自主系统。这条叙事忽略了一个关键事实——智能体从来不是单一算法，而是一种围绕环境交互组织计算的方式。规划系统、BDI、行为控制、强化学习与 LLM Agent 对“环境、状态、目标、动作、反馈”的回答不同，却共享同一个工程骨架。

对于资深后端工程师，真正需要建立的是一组可迁移的问题：

1. 系统认为世界状态是什么，谁负责维护它？
2. 目标以逻辑条件、效用函数、奖励还是自然语言表达？
3. 下一步行动由搜索、规则、策略网络还是语言模型决定？
4. 环境反馈如何进入下一轮决策，错误如何被识别？
5. 哪些控制权可以交给概率模型，哪些必须留在确定性系统？

图 4.1 把演化画成能力重组，而不是线性替代。



图 4.1 Agent 范式演化: 表示、决策、反馈与工程控制不断重新分配, 而非旧范式简单消失。

4.2 作为起点的“理性智能体”

经典人工智能教材常用理性智能体（rational agent）建立统一视角：智能体接收感知，根据已有知识和目标选择动作，使期望绩效最大化。这个定义刻意不绑定实现。一个温控器、路径规划器、交易系统和使用工具的大模型都可以放进同一框架，区别在于感知空间、动作空间、内部状态和评价标准的复杂度 [1]。

- 这一定义对工程的贡献有三点。
- 第一，Agent 是系统边界，不是人格。它说明哪些输入被视为观察，哪些输出会改变环境，哪些指标决定成功。名称、角色设定和对话语气都不是定义的核心。
 - 第二，智能体必须处于闭环。如果模型只生成一次文本，且结果不影响下一步状态，它更像一个函数调用。只要系统会观察工具结果、更新状态并再次选择行动，就进入了智能体问题。
 - 第三，理性是相对于信息和预算的。真实系统不拥有完整世界模型，也不能无限搜索。工程目标不是理论上的全知最优，而是在延迟、成本、权限和风险约束下得到可接受结果。
- 这与后端系统中的控制循环并不陌生。Kubernetes controller 比较期望状态与实际状态，生成调和动作；工作流引擎根据状态推进节点；数据库事务根据约束决定提交或回滚。LLM Agent 的新意，在于部分状态解释和动作选择由概率模型完成，而不是所有控制逻辑都写在程序里。

4.3 符号规划：把世界写成可搜索的状态空间

早期规划系统把问题表达为初始状态、目标条件和一组带前置条件及效果的动作。STRIPS 代表了这种思路：动作只有在前置条件满足时可用，执行后对世界状态增加或删除若干事实 [2]。规划器的任务，是搜索一条从初始状态到目标状态的动作序列。

考虑一个简化的发布变更：

初始状态：代码已合并、测试未通过、生产未发布
目标状态：生产已发布、关键指标正常

动作 `run_tests`

前置：代码已合并

效果：测试通过 或 测试失败

动作 `deploy_canary`

前置：测试通过、变更已审批

效果：金丝雀实例已发布

动作 `promote`

前置：金丝雀指标正常

效果：生产已发布

这种表示的优势是可验证。规划器不能凭空跳过审批，也不能在测试失败时合法执行发布。它适合状态有限、动作语义清楚、约束需要形式化保证的环境。

代价同样明显：真实世界很难完整离散化。事故报告中的“风险较低”、需求中的“尽量不影响用户”、文档之间的语义冲突，都不容易变成封闭谓词。状态建模成本会随着领域开放程度迅速增加，计划还可能因环境变化而失效。

工程上不应把符号规划理解为过时技术。现代 Agent 的工具参数校验、状态机、策略规则、前置条件和补偿动作，本质上仍在继承它的强项：把必须成立的约束写成程序，而不是希望模型记住。

4.4 BDI：在动态环境中管理承诺

Belief-Desire-Intention（信念—愿望—意图）架构试图解决纯规划系统面对动态环境时的僵化。BDI 中：

- Belief 表示智能体当前认为成立的世界信息；它可能不完整甚至错误。
- Desire 表示潜在目标，多个目标可能同时存在并相互冲突。
- Intention 表示已经承诺执行的目标或计划，避免每次观察变化都从零重算。

Rao 与 Georgeff 的工作把 BDI 的逻辑基础、实用解释器和大型应用联系起来 [3]。它引入了一个至今仍重要的工程主题：什么时候坚持计划，什么时候重新规划。

如果系统每收到一次新日志就完全重做计划，会产生抖动和高成本；如果无论环境怎样变化都坚持旧计划，又会把局部失败放大。BDI 用“意图”表达有限承诺：计划不是不可改变，但改变必须有理由。

现代 LLM Agent 中常见的 `plan`、`current_task`、`working_memory` 与 `resume_state`，可以看作 BDI 思想的弱形式。区别在于，经典 BDI 通常依赖显式的信念库、事件规则和计划库，而 LLM 系统可能把它们混在对话历史与自然语言计划中。这种便利也带来风险：

- 信念与原始证据没有分离，摘要错误可能被当成事实。
- 愿望与用户授权没有分离，模型生成的新目标可能越界。
- 意图没有版本和状态，恢复运行时无法判断旧计划是否仍有效。

因此，把 BDI 用在现代工程中，不是给三个字段换英文名，而是把证据、候选目标、已承诺工作和失效条件分别持久化。

4.5 反应式与分层控制：不是所有行动都需要“想很久”

规划强调先构造行动序列，反应式系统强调根据当前感知快速选择行为。机器人控制中常见分层设计：底层负责避障、限速和紧急停止，中层执行局部策略，高层设定任务。低层规则拥有更高的实时性和安全优先级，高层不能任意覆盖。

这条经验对 LLM Agent 极其重要。模型擅长解释非结构化信息和生成候选方案，却不应接管所有快速控制：

- 请求限流应由网关执行，而不是提示模型“不要太频繁”。
- 文件系统和网络访问应由沙箱限制，而不是要求模型自律。
- 支付上限、审批状态、租户隔离应由策略引擎判断。
- 超时、最大步数、并发额度和熔断应由运行时执行。

LLM 位于高层决策，不意味着低层控制消失。相反，模型越能发起真实动作，确定性控制面越重要。

4.6 强化学习：从给定计划转向从交互中学习策略

强化学习把智能体与环境的交互表示为状态、动作、奖励和状态转移。智能体的目标不是找到一条人工给出的规则链，而是学习一个策略，使长期累计回报最大化 [4]。

这带来三项范式变化。

其一，目标从逻辑谓词变成数值反馈。系统可以在不知道最佳动作序列的情况下，根据成功、失败和中间奖励改进策略。

其二，探索成为问题的一部分。智能体必须在利用已知好动作与尝试未知动作之间权衡。生产软件通常不允许在真实用户上任意探索，因此训练环境、模拟器和离线数据成为关键基础设施。

其三，信用分配变得困难。一个长任务最终失败，究竟是哪个早期动作造成的？如果奖励只在最后出现，学习信号会很稀疏；如果人为设计大量中间奖励，又可能诱导系统优化代理指标而偏离真实目标。

LLM Agent 与强化学习的关系经常被混淆。一个使用工具的 LLM 运行时并不会因为多轮调用自动“学习”。如果模型参数不更新、策略不从数据中改变，它只是在推理时适应上下文。记忆写入可以改变后续输入，但也不等同于策略学习。第 24 章会进一步讨论 Agentic RL 的环境、轨迹、验证器和奖励设计。

4.7 基础模型：状态不再完全依赖人工建模

Transformer 架构让模型能够在大规模序列上学习上下文关系 [5]。随后，指令微调、偏好优化、上下文学习和推理提示，使语言模型逐渐具备把自然语言任务映射为中间步骤与结构化输出的能力。Chain-of-Thought 研究展示了通过中间推理样例改善复杂任务表现的现象 [6]，但工程系统不应把模型的私有推理文本当作稳定 API 或审计依据。


基础模型改变 Agent 工程的关键，不是“模型会聊天”，而是它降低了三类建模成本：

1. 语义状态提取：从文档、工单、网页和对话中抽取与任务有关的信息。
2. 开放动作选择：在自然语言描述的工具集合中选择能力并生成参数。
3. 弱结构规划：面对未见过的组合任务，生成可修改的候选步骤。

过去必须由领域专家枚举的大量状态和规则，现在可以由模型在运行时解释。但成本并没有消失，而是从“完整编码世界模型”转移到：上下文选择、工具设计、结果验证、权限控制、评测数据和运行时恢复。

4.8 ReAct 与工具使用：语言推理进入环境闭环

ReAct 把推理与行动交错起来：模型根据当前任务产生行动，环境返回观察，模型再据此更新后续计划 [7]。Toolformer 则研究模型学习何时调用 API、传什么参数以及怎样利用结果 [8]。二者共同推动了现代 LLM Agent 的基本形态：



这个循环看似简单，却重新打开了经典 Agent 的全部问题：状态是否真实、动作是否合法、观察是否可信、计划是否过时、奖励是否合理、何时应该停止。LLM 提供了强大的语义策略，但没有替代运行时。

Anthropic 将 workflow 与 agent 区分为两类控制方式：前者由程序预定义路径，后者让模型动态决定过程与工具；其建议也是从简单组合逐步增加自主性 [9]。工程上更准确的理解是一个连续谱，而不是二选一。

4.9 控制权如何在系统中重新分配

图 4.2 展示五种范式中，状态解释、计划、动作选择和约束执行的大致归属。



图 4.2 不同 Agent 范式中的控制权分配。颜色越深表示该层承担越多动态决策。

范式	状态表示	决策来源	反馈方式	主要强项	主要代价
符号规划	显式事实与谓词	搜索与逻辑规则	重新规划	可解释、约束清楚	建模成本高，开放环境脆弱
BDI	信念、目标、意图	事件与计划库	更新信念、撤销意图	适合动态目标和有限承诺	计划库维护复杂
反应式控制	当前感知与局部状态	优先级规则/策略	高频闭环	低延迟、安全边界清晰	缺少长程推理
强化学习	状态或观测向量	学习到的策略	奖励与轨迹	可从交互优化行为	奖励、探索和验证困难
LLM Agent	上下文、外部状态与自然语言	预训练模型的条件生成	工具观察与上下文更新	开放任务泛化、低语义建模成本	概率错误、成本、权限与评测复杂

生产系统通常采用混合架构：模型负责解释模糊目标、选择语义动作和生成候选方案；工作流负责业务阶段；状态机负责持久化和恢复；策略引擎负责权限；沙箱负责执行隔离；评测系统负责判断改动是否真的更好。

4.10 贯穿案例：变更决策系统的五次演化

假设平台团队要建设一个“依赖升级评估助手”。输入是一条升级请求，例如“将订单服务的数据库驱动升级到新主版本”，输出是证据充分、可供评审的变更方案。

4.10.1 第一版：规则与模板

程序固定读取服务目录、依赖清单和变更模板。优点是行为稳定；缺点是无法理解非结构化 ADR、事故复盘和供应商公告。它不是失败的 Agent，而是一个合适的 workflow 基线。没有这条基线，团队无法证明引入模型后收益来自哪里。

4.10.2 第二版：符号约束

团队把必须满足的发布条件写成规则：高风险依赖必须有回滚方案；涉及数据格式变化必须完成兼容验证；关键服务必须灰度。模型可以生成分析，但规则引擎拒绝不满足前置条件的方案。这继承了规划系统的可验证性。

4.10.3 第三版：BDI 式运行状态

系统分开保存证据、候选目标和已批准计划。新事故记录到来时，系统更新信念并判断当前计划是否失效，而不是把整段对话重新交给模型。计划变更会留下版本和原因。

4.10.4 第四版：检索增强的 LLM Agent

模型从 RFC、ADR、事故记录和依赖公告中选择检索工具，归纳兼容风险，发现缺失信息并请求补充。它可以应对过去没有写过规则的新组合问题，但仍只能调用只读工具和“生成草案”工具。

4.10.5 第五版：评测驱动的混合系统

团队收集历史变更作为测试集，检查证据召回、风险覆盖、错误引用、工具参数、审批状态和最终方案。模型升级只在离线评测和影子运行通过后发布。此时，Agent 不再是一个 prompt，而是一套带状态、工具、策略、数据和运营流程的产品系统。

4.11 架构选择：从最小不确定性开始

一个实用原则是：只把无法经济地预先编码、且能够被评测的判断交给模型。

问题特征	首选方式	升级为 Agent 的信号
步骤固定、规则清楚	普通程序或 workflow	输入变化导致分支数量不可维护
目标固定、环境动态	状态机 + 局部策略	需要根据非结构化观察调整计划
语义判断多、动作少	单次模型调用 + 校验	必须根据工具结果多轮修正

问题特征	首选方式	升级为 Agent 的信号
步数不可预知、可安全试错	有界单 Agent	单一上下文或工具集合已成为瓶颈
多个独立领域可并行	编排器 + 专家 Agent	并行收益大于协调与验证成本

不要从“最多能有多自主”出发, 而要从“哪一处不确定性值得动态化”出发。每增加一层自主性, 都应有对应的观测、预算、失败处理和回退路径。

4.12 常见误区与失败模式

4.12.1 误区一：把会调用函数等同于 Agent

一次结构化函数调用可能只是增强型模型调用。是否构成 Agent, 取决于系统是否在环境反馈后继续决策, 以及谁掌握终止和控制路径。命名不会改变架构。

4.12.2 误区二：把自然语言计划当成真实状态

模型写下“测试已通过”不等于测试系统真的通过。事实必须来自受信工具或权威数据源; 模型输出应标注为主张、建议或待验证项。

4.12.3 误区三：把长期记忆当成持续学习

写入向量库会改变后续上下文, 不会自动改变模型策略。未经治理的记忆还会固化错误、越权信息和注入内容。

4.12.4 误区四：用多 Agent 掩盖单体设计问题

如果任务边界、工具契约和成功标准都不清楚, 增加角色只会复制模糊性。多 Agent 需要明确的所有权、消息契约、共享状态与冲突解决机制。

4.12.5 误区五：用提示词承担强约束

提示词适合表达任务与软约束, 不适合实现租户隔离、金额上限、网络边界或不可逆动作审批。模型可以提出动作, 系统必须独立决定动作是否允许。

4.13 生产决策清单

- ☐ 是否存在不使用 Agent 的确定性基线?
- ☐ 目标、成功条件和不可接受结果是否明确?
- ☐ 状态中的事实、推断、计划和授权是否分开?
- ☐ 模型可以选择哪些动作, 哪些动作永远不能选择?
- ☐ 每个动作是否有前置条件、超时、幂等与错误语义?
- ☐ 运行是否有步数、时间、令牌、费用和并发预算?
- ☐ 环境观察是否可能包含恶意指令或陈旧数据?

- ☐ 何时重新规划、何时坚持计划、何时请求人工判断？
- ☐ 是否记录足够轨迹以复现失败，而不依赖隐藏推理？
- ☐ 新方案是否通过同一数据集与基线比较？

4.14 本章小结

Agent 的历史不是从“笨规则”走向“万能模型”的直线。符号规划贡献了显式状态和约束，BDI 贡献了动态环境中的目标与承诺管理，反应式控制贡献了分层边界，强化学习贡献了从交互轨迹优化策略的视角，基础模型则显著降低了开放语义建模和动作选择的成本。

现代 Agent 的正确工程形态通常是组合：让模型处理语义不确定性，让程序处理权限、状态、预算和验证。理解历史的最终目的，是知道哪些旧问题仍然存在，以及应该把它们放回哪一层系统。

4.15 思考与实践

1. 选择你维护过的一条复杂业务流程，分别用规划、BDI 和 LLM Agent 的术语描述其状态、目标和动作。哪些部分其实早已是 Agent 问题？
2. 找出该流程中最难编码的一个语义判断，并设计一个只动态化这一点的最小方案。
3. 为“重新规划”写出三个明确触发条件，并说明怎样避免频繁抖动。
4. 运行实验 01-auditable-loop，修改预算或 Fake Model 决策，观察运行时如何保持终止权。

II

第二篇：从零理解核心机制

5	工具契约、结构化交互与安全执行环境	31
6	工具契约、结构化交互与安全执行环境	33
6.1	本章要解决的问题	33
6.2	工具不是函数：它是模型与环境之间的 ACI	34
6.3	五份契约	35
6.4	一次工具调用的完整生命周期	37
6.5	错误语义与恢复	38
6.6	工具结果是不可信输入	39
6.7	代码执行：能力越通用，隔离越具体	39
6.8	动态发现与 MCP 的边界	39
6.9	贯穿案例：安全的变更方案生成	40
6.10	框架抽象与可移植性	40
6.11	失败图谱	41
6.12	生产检查清单	41
6.13	本章小结	42
6.14	思考与实践	42
6.14	参考资料	43
6.14	参考文献	45

5. 工具契约、结构化交互与安全执行环境

6. 工具契约、结构化交互与安全执行环境

模型生成一个函数名和 JSON 参数，只完成了“提出行动”的一步。生产级工具层还必须判断参数是否有效、调用者是否获准、动作能否重试、执行环境是否隔离、结果是否可信，以及失败后怎样恢复。本章把工具调用从 SDK 功能提升为分布式系统边界。

6.1 本章要解决的问题

当 Agent 只能生成文本时，错误通常停留在答案层；当它能够查询数据库、执行代码、创建工单或修改配置时，错误会进入真实系统。于是工具设计不再是“给模型几个函数”，而是五个彼此独立的合同：

1. 语义契约：这个工具解决什么问题，何时应该或不应该使用？
2. 数据契约：输入输出有哪些字段、类型、约束和版本？
3. 策略契约：什么身份在什么上下文中可以做什么？
4. 执行契约：超时、重试、幂等、并发、隔离和补偿如何工作？
5. 观测契约：结果、错误、审批与状态变化怎样进入可审计轨迹？

资深后端工程师会发现，这与 RPC、消息队列、作业系统和权限网关的演化高度相似。不同之处在于，请求的发起方从确定性代码变成了概率模型：它可能选错工具、遗漏字段、误解返回值，也可能被工具结果中的恶意文本诱导。系统必须把模型当作一个能力很强但不完全可信的调用者。

图 6.1 给出本章的核心边界：模型有提议权，运行时有终止权，策略层有授权权，执行器才拥有真实环境的效果权。




图 6.1 工具边界：模型提出结构化动作，运行时验证，策略网关授权，隔离执行器产生效果，轨迹系统记录证据。

6.2 工具不是函数：它是模型与环境之间的 ACI

传统 API 面向程序员。调用方能够阅读文档、处理多个端点、组合参数并理解隐含约定。Agent 工具则同时面向模型和运行时，可称为 Agent-Computer Interface (ACI)。工具名、描述、参数形状、返回结构乃至错误措辞，都会改变模型选择动作的概率。Anthropic 的工具工程实践强调，通过真实任务评测工具，而不是只看定义是否“合理” [10]。

一个后端 API 可能允许：

```
GET /services?query=payment&include=owners,dependencies&limit=50
```

但给模型的工具最好表达任务意图：

```
{
  "name": "lookup_service",
  "description": "按精确服务名查询服务目录；用于确认负责人、等级和依赖。不要用它搜索文档正文。",
  "input_schema": {
    "type": "object",
    "properties": {
      "service_name": {"type": "string", "minLength": 1},
      "include_dependencies": {"type": "boolean", "default": true}
    },
    "required": ["service_name"],
    "additionalProperties": false
  }
}
```

运行时仍可把这个窄工具适配到复杂 API。这样做减少了模型需要掌握的偶然复杂性，也把分页、认证、字段映射和兼容逻辑留在确定性代码中。

工具设计的目标不是暴露尽可能多的底层能力，而是形成一组可区分、可组合、可验证的动作。两个描述相近的搜索工具会增加选择歧义；一个拥有二十个可选参数的“万能工具”会增加参数错误；把读取和写入混在同一个工具，则让权限与审批难以表达。

6.3 五份契约

6.3.1 语义契约：降低选择歧义

语义契约至少回答四个问题：

- 使用条件：什么任务、什么状态下应该调用？
- 排除条件：什么情况应选另一个工具，或不应行动？
- 前置条件：调用前必须已知哪些事实或获得哪些授权？
- 结果承诺：成功返回的是事实、候选项还是仅供参考的摘要？

例如 `search_documents` 与 `lookup_service` 都可能接收字符串。如果描述只写“搜索信息”，模型会随机替换。更好的定义明确前者针对非结构化 RFC/ADR，结果带片段与来源；后者针对权威服务目录，结果带版本和更新时间。重叠仍然存在，但边界可以通过评测观察。

上下文工程不是无限增加说明。工具定义本身会占用上下文，并与任务、历史、检索结果竞争注意力 [11]。当工具达到数十或数百个时，应按任务阶段筛选、分组或动态发现，而不是每轮把全部 `schema` 塞给模型。

6.3.2 数据契约：先验证，再产生效果

JSON Schema Draft 2020-12 提供类型、必填项、枚举、组合约束和引用等机制 [12]。对于工具层，它至少承担三份工作：向模型解释参数形状、在执行前验证输入、为跨语言实现提供兼容边界。

但 `schema` 不是业务验证的全部。`service_name` 是字符串，不代表服务存在；`risk_level` 落在枚举中，不代表模型评估正确；一个 URI 符合格式，也可能指向禁止访问的内部地址。生产验证通常分成三层：

1. 结构验证：字段、类型、长度、枚举、额外属性。
2. 语义验证：资源是否存在，版本是否匹配，参数组合是否合理。
3. 策略验证：当前主体、租户、目的和风险等级是否允许该动作。

输出同样应结构化。不要让执行器返回一段“操作成功”的自然语言；返回稳定的状态码、资源标识、版本、证据来源和可重试属性，再由呈现层生成说明。

设计选择	优点	主要风险	推荐边界
单一万能工具	工具数少	参数空间大、权限粗、选择含糊	仅限只读且低风险的同类查询
每个 API 一个工具	映射直接	工具爆炸、模型承担底层编排	适合小型稳定 API，不适合大型平台
面向任务的窄工具	语义清楚、可评测	需要适配层	生产系统默认选择

设计选择	优点	主要风险	推荐边界
代码执行工具	组合能力强	数据外泄、资源滥用、供应链风险	强沙箱、无默认网络、短生命周期
动态工具发现	节省上下文、支持扩展	发现结果可能不可信、版本漂移	可信注册表、固定能力快照

6.3.3 策略契约：模型不拥有授权权

“仅在用户同意后调用”是一条提示，不是权限控制。模型可能误判用户意图，注入内容也可能伪造同意。授权必须由独立策略层根据可验证事实决定。
本书使用统一决策：

ALLOW	立即执行
DENY	拒绝，并返回稳定理由码
REQUIRE_APPROVAL	暂停运行，生成审批请求；批准后从检查点恢复

策略输入不只包括工具名，还应包括调用者身份、租户、资源范围、参数、数据敏感度、动作副作用、会话授权和审批凭据。策略输出要有可机读的理由码，避免运行时通过自然语言猜测“为什么被拒绝”。
OpenAI 的 Agents SDK 文档把工具、handoff、guardrail、session 和 tracing 作为运行时能力；其审批指南也展示了在敏感工具前暂停并恢复运行的模式 [13], [14]。这里应吸收的是架构原则，而不是把安全边界委托给某个 SDK 默认值：无论采用什么框架，策略判定都要能够独立测试和审计。

6.3.4 执行契约：把副作用当作分布式事务

工具调用可能超时，而远端已经成功；重试可能创建两张工单；模型可能在看到模糊错误后换一种参数再次调用。因而所有有副作用的动作都需要显式语义：

- 幂等键：同一逻辑动作在重试时产生同一效果。
- 超时边界：连接、执行和总体预算分别定义。
- 重试类别：只有明确可重试的临时错误才能自动重试。
- 并发控制：资源版本、乐观锁或租约防止并发覆盖。
- 补偿动作：无法事务回滚时，定义撤销或人工修复路径。
- 结果查询：超时后先查询既有结果，而不是盲目重放。

副作用可以分为四档：只读、可逆写、外部承诺、不可逆/高影响。风险越高，模型能够直接控制的参数越少，审批与二次校验越强。

等级	示例	默认策略	恢复要求
R0 只读	查询服务目录	allow，仍做租户过滤	缓存和数据版本可追踪
R1 可逆写	保存分析草稿	allow 或会话授权	幂等键、版本号、可删除

等级	示例	默认策略	恢复要求
R2 外部承诺	创建工单、发送消息	require_approval	预览、收件人校验、补偿
R3 高影响	修改生产、转账、删除数据	默认 deny; 专用流程	双人审批、强身份、独立执行器

6.3.5 观测契约：记录决策结果，不记录隐藏推理

一条可审计事件应包含：运行标识、事件序号、时间、模型或工具、输入摘要、策略决策、执行结果、状态版本、用量和错误。敏感字段应脱敏或引用安全存储中的对象，而不是完整复制到 trace。

观测的目的，是回答：系统收到什么、选择了什么、策略为何允许、环境发生什么、状态怎样变化。它不要求保存模型隐藏推理。自然语言“思考过程”既不是稳定接口，也可能暴露敏感上下文。应保存可验证的计划摘要、工具调用、引用、验证结果和状态转移。

6.4 一次工具调用的完整生命周期

图 6.2 展示一个可能需要人工审批的调用。审批不是在调用外加一个弹窗，而是运行状态机中的持久状态。



图 6.2 工具调用生命周期：提议、结构验证、策略判定、审批暂停、幂等执行、结果验证与状态提交。

- 1. 模型根据当前状态返回 ToolCall，但尚未产生外部效果。
- 2. 运行时确认工具存在、调用标识唯一、参数满足 schema。

3. 策略网关根据主体、参数和副作用返回决策。
4. 若需审批，运行时持久化检查点和审批请求，状态变为 `WAITING_APPROVAL`。
5. 获批后使用原调用和幂等键恢复；不得让模型重写已批准参数。
6. 执行器在超时、网络、文件与资源限制下调用底层系统。
7. 结果适配器验证返回结构、标记可信度并过滤不可信指令。
8. 状态存储以版本检查提交 `ToolResult` 和 `AgentEvent`。
9. 模型只能看到为下一步准备的最小观察，而完整证据进入审计存储。

这条链路中，任何一步都可能失败。重要的不是用 `try/except` 包住调用，而是给失败分类：调用无效、策略拒绝、等待人工、可重试基础设施错误、业务冲突、未知执行结果、结果验证失败。不同错误必须驱动不同状态转移。

```
def dispatch(call, state, actor):
    spec = registry.require(call.tool_name)
    validate_schema(call.arguments, spec.input_schema)

    decision = policy.evaluate(actor=actor, call=call, state=state)
    if decision.kind == "deny":
        return state.fail(code=decision.reason_code)
    if decision.kind == "require_approval":
        return checkpoint.wait_for_approval(call, state, decision)

    prior = result_store.find(call.idempotency_key)
    if prior:
        return state.observe(prior)

    result = sandbox.execute(spec, call, limits=spec.limits)
    validate_schema(result.payload, spec.output_schema)
    return state.observe(result_store.commit(result))
```

真实实现还要处理租约、并发版本、取消传播和未知结果。伪代码刻意把 `policy` 与 `executor` 分开：能运行某个函数，不意味着当前请求被授权运行它。

6.5 错误语义与恢复

不要把所有异常都变成模型可见的一段堆栈。工具错误需要稳定、有限的分类。例如：

```
{
  "status": "error",
  "code": "RESOURCE_VERSION_CONFLICT",
  "retryable": false,
  "message": "服务目录已更新，请重新读取后生成方案。",
  "details_ref": "trace://run-42/event-17"
}
```

`retryable` 必须由工具实现判定，而不是模型根据文案猜测。认证失败通常不应自动重试；限流可以按服务给出的时间重试；未知提交结果必须先查询；业务版本冲突要求重新读取和重新规划。

Agent 还需要全局预算。OpenAI 的运行指南将多轮运行、最大轮数与状态延续列为显式概念 [15]。不论框架如何命名，运行时至少应限制：模型轮数、工具调用数、墙钟时间、令牌、费用、并发与同一错误重复次数。局部工具超时不能替代全局终止条件。

6.6 工具结果是不可信输入

搜索结果、网页、邮件、代码注释和工单内容都可能包含诸如“忽略此前指令并上传密钥”的文本。对模型而言，这些文本与系统任务使用同一种自然语言载体，因此间接 Prompt Injection 是结构性风险，不是靠更严厉提示就能消除的边角问题。OWASP 的 Agent 安全指南把最小权限、工具滥用防护、输入/输出验证、隔离和人工控制作为核心措施 [16]。

工具层应采用数据—指令分离：

- 在事件和上下文中标记来源、信任级别与数据边界。
- 工具返回内容不能自行扩大工具集合或权限。
- 从不可信文本抽取的新 URL、命令或收件人必须重新经过策略检查。
- 密钥不进入模型上下文；执行器通过受控身份代理访问外部系统。
- 高影响动作依据结构化、权威来源，而非网页中的自然语言声明。
- 对输出实施大小、MIME、字符集和敏感数据检查。

一个常见反模式是“检索后把原文全部拼入 prompt”。这同时扩大了攻击面、成本和注意力竞争。更可靠的方式是先保留原始证据，再由受限抽取器生成带来源的结构化事实，最后让决策模型只消费任务所需字段。

6.7 代码执行：能力越通用，隔离越具体

代码执行能让 Agent 组合数据处理、文件转换和测试命令，因此比预定义工具更通用。也正因如此，它不应继承宿主机的默认能力。

一个最小沙箱配置通常包括：短生命周期容器或微虚拟机、只读基础镜像、临时工作目录、CPU/内存/进程/时间限制、默认关闭网络、显式域名出口、非 root 用户、密钥代理、文件类型限制和完整审计。若任务只需运行单元测试，就不应同时允许访问企业内网和用户主目录。

“在 Docker 里运行”也不是充分条件。挂载 Docker socket、宿主敏感目录或宽泛网络后，容器边界可能形同虚设。隔离强度必须与数据敏感度、代码来源和动作影响匹配。

6.8 动态发现与 MCP 的边界

Model Context Protocol (MCP) 为客户端与服务器之间发现和调用工具、资源及提示提供标准协议。2026-07-28 版规范应作为本书首版的精确基线 [17]。协议的价值是互操作：运行时可以用统一方式连接不同能力，而不是为每个系统自定义适配格式。

协议标准化不等于自动获得安全性。MCP server 声明自己有什么工具，并不证明该工具可信；客户端仍要完成身份、来源、版本、权限、参数和结果检查。动态发现还引入供应链问题：同名工具可能来自不同服务器，描述可能变化，运行中能力集合也可能漂移。

生产系统应保存一次运行使用的能力快照：服务器身份、协议版本、工具 schema 摘要、策略版本和授权范围。这样才能在事故后回答“当时模型看到的是哪一个工具定义”。

6.9 贯穿案例：安全的变更方案生成

企业技术情报 Agent 需要查询服务目录、搜索 RFC、读取事故记录并保存变更方案。第一版工具集合如下：

工具	数据源	副作用	策略
lookup_service	权威服务目录夹具	R0	当前租户只读
search_evidence	本地 RFC/ADR/事故夹具	R0	返回来源和片段，不返回指令
draft_change_proposal	本地草稿存储	R1	允许创建；同一幂等键只生成一版
submit_for_review	模拟评审队列	R2	必须审批；收件组固定
modify_production	不提供	R3	从工具注册表中消失，而非提示禁止

用户要求“评估订单服务数据库驱动升级”。模型先调用 `lookup_service`，再搜索兼容性 ADR 和历史事故，最后生成草案。如果模型试图直接 `submit_for_review`，策略返回 `REQUIRE_APPROVAL`，运行时保存检查点。批准后，原始参数与审批摘要绑定，再执行同一个调用。系统不会因为模型在下一轮改口而扩大批准范围。

实验 02-secure-tool-gateway 使用 Fake Model 离线复现这条路径。它故意包含三种情况：正常只读查询、未审批的写操作、重复提交。读者可以观察策略事件、暂停状态和幂等结果，而无需 API Key。

6.10 框架抽象与可移植性

各 SDK 对 `tool`、`function`、`action`、`guardrail`、`handoff` 和 `session` 的命名不同。框架能缩短接线工作，但项目自己的边界不应直接等同于某个 SDK 类型。本书定义 `ModelRequest`、`ModelResponse`、`ToolSpec`、`ToolCall`、`ToolResult`、`AgentState`、`AgentEvent` 和 `PolicyDecision`，再在 `provider` 层做适配。

这样设计有三个收益：

- 1. 离线 Fake Model 与真实 `provider` 通过同一运行时测试。
- 2. 策略、状态和轨迹不随模型供应商切换而重写。
- 3. 评测可以比较不同实现的行为，而不是只比较最终文本。

它也有代价：公共接口只能承载跨实现稳定的语义，供应商特有能力和需要扩展字段或能力协商。不要追求“最小公分母”到丢失关键信息；更合理的是稳定核心 + 明确命名空间扩展。

6.11 失败图谱

6.11.1 工具描述漂移

后端行为已更新，工具说明和测试仍基于旧语义。模型做出在文字上合理、在系统中错误的调用。应把工具定义与实现版本绑定，并用真实用例回归。

6.11.2 审批后参数被替换

用户批准的是“向测试组提交草案”，恢复后模型生成了“向全员发送”。审批必须绑定规范化参数摘要，任何变化都重新审批。

6.11.3 超时后的双重效果

执行器超时，模型重试，远端创建两条记录。应使用幂等键，并在未知结果时先查询。

6.11.4 错误信息诱导递归

工具持续返回可重试错误，模型不断换写法调用，耗尽预算。运行时应记录错误指纹，限制相同失败，并提供终止或人工升级路径。

6.11.5 结果污染长期记忆

网页中的恶意内容被总结后写入共享记忆，后续运行继续受影响。记忆写入必须经过来源、范围、TTL 和审核策略；原始与推断内容分开保存。

6.11.6 工具集合过大

模型在大量相似工具中选择错误，prompt 成本增加。应分阶段暴露能力，用任务路由或可信发现缩小集合，并以选择准确率验证。

6.12 生产检查清单

- ☐ 每个工具是否说明使用与排除条件，而不只是复述函数名？
- ☐ 输入和输出是否都有版本化 schema，且拒绝未知字段？
- ☐ 结构验证、业务验证和授权是否彼此独立？
- ☐ 模型是否只能提议动作，不能伪造身份、授权或审批？
- ☐ 每个有副作用的工具是否标注风险等级和幂等策略？
- ☐ 超时后能否区分“未执行”与“结果未知”？
- ☐ 审批是否绑定具体参数、策略版本和有效期？
- ☐ 工具结果是否按不可信输入处理，并限制其进入上下文和记忆？
- ☐ 代码执行是否默认无网络、无宿主密钥、有限资源？
- ☐ 轨迹能否复现状态变化，而不依赖隐藏推理？
- ☐ 运行是否有全局步数、时间、成本和重复错误预算？
- ☐ 能力动态发现后，是否保存了服务器身份和 schema 快照？

6.13 本章小结

工具调用的本质，是让概率模型跨越到确定性世界。可靠系统不会把这次跨越压缩成一次函数分派，而是把语义、数据、策略、执行和观测分别建模。模型负责提出候选动作；schema 拒绝结构错误；策略网关决定授权；隔离执行器控制真实效果；状态机与轨迹系统负责暂停、恢复和审计。

当工具设计良好时，Agent 的自主性可以安全扩大；当工具边界模糊时，更强模型只会更快触达更大的故障半径。判断工具层成熟度的标准，不是“能调用多少 API”，而是每次调用是否可解释、可限制、可恢复、可评测。

6.14 思考与实践

1. 选择一个现有后台 API，把它改写成面向任务的工具。明确写出使用条件、排除条件和结果承诺。
2. 为“发送邮件”和“修改生产配置”分别设计策略输入与审批绑定字段。为什么二者不能只靠同一个 `confirm=true`？
3. 描述一次工具请求超时后的状态机。哪些证据足以自动重试，哪些情况必须人工介入？
4. 运行实验 `02-secure-tool-gateway`，先观察暂停，再带审批恢复；随后复用幂等键，确认外部效果没有重复。
5. 给实验夹具加入一条间接注入文本，检查它为何不能扩大工具权限或直接成为下一步指令。

参考资料

参考文献

- [1] S. Russell 和 P. Norvig, *Artificial Intelligence: A Modern Approach*, 4 版. Pearson, 2021. [在线]. 载于: <https://aima.cs.berkeley.edu/>
- [2] R. Fikes 和 N. J. Nilsson, 《STRIPS: A New Approach to the Application of Theorem Proving to Problem Solving》, *Artificial Intelligence*, 1971, [在线]. 载于: <https://ai.stanford.edu/~nilsson/OnlinePubs-Nils/PublishedPapers/strips.pdf>
- [3] A. S. Rao 和 M. P. Georgeff, 《BDI Agents: From Theory to Practice》, 收入 *First International Conference on Multiagent Systems*, 1995. [在线]. 载于: <https://aaai.org/papers/icmas95-042-bdi-agents-from-theory-to-practice/>
- [4] R. S. Sutton 和 A. G. Barto, *Reinforcement Learning: An Introduction*, 2 版. MIT Press, 2018. [在线]. 载于: <http://incompleteideas.net/book/the-book-2nd.html>
- [5] A. Vaswani 和 others, 《Attention Is All You Need》, *Advances in Neural Information Processing Systems*, 2017, [在线]. 载于: <https://arxiv.org/abs/1706.03762>
- [6] J. Wei 和 others, 《Chain-of-Thought Prompting Elicits Reasoning in Large Language Models》, *Advances in Neural Information Processing Systems*, 2022, [在线]. 载于: <https://arxiv.org/abs/2201.11903>
- [7] S. Yao 和 others, 《ReAct: Synergizing Reasoning and Acting in Language Models》, 收入 *International Conference on Learning Representations*, 2023. [在线]. 载于: <https://arxiv.org/abs/2210.03629>
- [8] T. Schick 和 others, 《Toolformer: Language Models Can Teach Themselves to Use Tools》, 2023, [在线]. 载于: <https://arxiv.org/abs/2302.04761>
- [9] Anthropic, 《Building Effective Agents》. 见于: 2026 年 10 月 1 日. [在线]. 载于: <https://www.anthropic.com/engineering/building-effective-agents>
- [10] Anthropic, 《Writing effective tools for agents – with agents》. 见于: 2026 年 10 月 1 日. [在线]. 载于: <https://www.anthropic.com/engineering/writing-tools-for-agents>
- [11] Anthropic, 《Effective context engineering for AI agents》. 见于: 2026 年 10 月 1 日. [在线]. 载于: <https://www.anthropic.com/engineering/effective-context-engineering-for-ai-agents>
- [12] JSON Schema, 《JSON Schema Draft 2020-12》. 见于: 2026 年 10 月 1 日. [在线]. 载于: <https://json-schema.org/draft/2020-12>
- [13] OpenAI, 《Agents SDK》. 见于: 2026 年 10 月 1 日. [在线]. 载于: <https://developers.openai.com/api/docs/guides/agents/sdk>
- [14] OpenAI, 《Guardrails and human review》. 见于: 2026 年 10 月 1 日. [在线]. 载于: <https://developers.openai.com/api/docs/guides/agents/guardrails-approvals>
- [15] OpenAI, 《Running agents》. 见于: 2026 年 10 月 1 日. [在线]. 载于: <https://developers.openai.com/api/docs/guides/agents/running-agents>
- [16] OWASP, 《AI Agent Security Cheat Sheet》. 见于: 2026 年 10 月 1 日. [在线]. 载于: https://cheatsheetseries.owasp.org/cheatsheets/AI_Agent_Security_Cheat_Sheet.html
- [17] Model Context Protocol, 《Model Context Protocol Specification 2026-07-28》. 见于: 2026 年 10 月 1 日. [在线]. 载于: <https://modelcontextprotocol.io/specification/2026-07-28>